

DOI: 10.3969/j.issn.1674-0696.2024.09.07

引文格式: 丁建立, 刘德康. 机场航班延误恢复的强化学习算法[J]. 重庆交通大学学报(自然科学版), 2024, 43(9): 50-58.

Citation: DING Jianli, LIU Dekang. Reinforcement learning algorithm for airport flight delay recovery[J]. *Journal of Chongqing Jiaotong University (Natural Science)*, 2024, 43(9): 50-58.

机场航班延误恢复的强化学习算法

丁建立, 刘德康

(中国民航大学 计算机科学与技术学院, 天津 300300)

摘要: 机场出现航班延误会导致飞行器和乘客滞留机场, 若航班延误恢复调度不当会扩大延误造成的损失。针对航班延误恢复调度的损失最小化问题, 设计了延误总损失计算的目标函数, 构建航班延误恢复马尔科夫决策过程, 建立了机场航班延误恢复重排班模型。为了解决计算的复杂性问题, 采用深度学习神经网络参数化策略函数对减小延误损失目标函数值的策略进行参数化, 利用奖励函数和优势函数对其进行训练, 提出了一种机场航班延误恢复强化学习算法。研究表明: 该算法能够将航班延误总损失降低 7.83%, 将旅客延误时长降低 7.23%, 相比于其他算法, 该算法在时间和性能上均取得优势。

关键词: 交通运输工程; 航班延误恢复; 延误损失; 航班重排班; 马尔科夫决策; 深度强化学习

中图分类号: U8; TP399

文献标志码: A

文章编号: 1674-0696(2024)09-050-09

Reinforcement Learning Algorithm for Airport Flight Delay Recovery

DING Jianli, LIU Dekang

(School of Computer Science and Technology, Civil Aviation University of China, Tianjin 300300, China)

Abstract: Flight delays at airports resulted in aircraft and passengers being stranded at the airport, and improper recovery and scheduling of flight delays can exacerbate the losses caused by delays. Aiming to the issue of minimizing losses in flight delay recovery scheduling, a target function was formulated to calculate the total delay loss, a Markov decision-making process was constructed for flight delay recovery, and an airport flight delay recovery rescheduling model was established. To address computational complexity, a deep learning neural network parameterized policy function was employed to parameterize the strategy of reducing the delay loss objective function value, which was trained by the reward function and advantage function. A reinforcement learning algorithm for airport flight delay recovery was proposed. The research results show that the proposed model can reduce the total loss of flight delays by 7.83% and the duration of passenger delays by 7.23%. The proposed deep reinforcement learning algorithm outperforms other algorithms in both time and performance.

Key words: traffic and transportation engineering; flight delay recovery; delay losses; flight rescheduling; Markov decision; deep reinforcement learning

0 引言

航班计划表是航空公司提前几个月制定好的班期计划。而考虑到航班执行受许多随机因素的影

响, 例如天气、交通、计划外维修或不可预测的人为因素等, 航班的实际执行情况和初始航班计划表之间出现偏差, 从而导致机场、航空公司和旅客受到经济损失, 因此不正常航班恢复问题是民航业务日常

收稿日期: 2023-10-10; 修订日期: 2024-03-05

基金项目: 国家自然科学基金民航联合研究基金重点支持项目(U2033205, U2233214)

第一作者: 丁建立(1963—), 男, 河南洛阳人, 教授, 博士, 主要从事智能仿生算法及民航应用、民航大数据及智能信息服务等方面的研究。

E-mail: jlding@cauc.edu.cn

通信作者: 刘德康(1999—), 男, 山东济宁人, 硕士, 主要从事航班延误恢复、强化学习方面的研究。E-mail: 2021052071@cauc.edu.cn

运营中的一个重要部分。一般来说紧密排列飞行器的飞行任务可以让机场和航空公司利润最大化,但是同时却很难留出足够的吸收能力来应对整个飞行计划期间的潜在延误。大多数民航机场已经建立了机场协同决策系统(A-CDM),以便在需要时进行航班监控并适当调整航班计划表。然而,到目前为止,典型的A-CDM系统控制仍然需要大量控制人员手动操作,A-CDM控制人员需要经常检查航班是否延迟并采取措施纠正不正常的航班调度。各个机场将根据各自运营情况和技术经验,结合数据库查询系统的使用,对发生延误的航班进行延误恢复重排班。根据航班偏离的严重程度,把提出的解决方案在机场内部进行评估,或者在航空公司的网络运营中心进行协调。然而,随着民航业不断的发展,这种航班延误恢复的方式已越来越不适应市场对航班延误恢复的实时性及排班效果上的要求。此外,在数字中国及国有资产数字化转型浪潮的推动下,机场建设迎来了数字化转型的高峰时期。因此民航业迫切需要一种能够根据机场延误情况在发生延误时进行延误恢复并降低损失的重排班算法。航班延误恢复问题作为一种实时最优化问题,其求解过程和需要考虑的因素十分复杂,属于NP-hard难题。这类动态优化问题的求解复杂度随着决策量和状态变量观测量的增加呈指数级增长,此计算挑战被称为维度诅咒。近几年来,关于航班延误恢复排班算法的研究主要集中在航班过站时间重分配、列向量生成算法、元启发式优化算法以及深度强化学习等方面。

2017年,Ö.ŞAFKAK等^[1]试图重新分配飞机在机场的过站时间,使飞行器在中转过程中可以最大程度吸收延误,以缓解延误造成的损失。2019年,WU Chenglung等^[2]基于历史飞行数据分析航班计划表中易出现延误的环节,针对特定环节减少延误及延误损失。2020年,何坚等^[3]引入了有效中转时间的概念,通过重新设置航班的有效中转时间,同时使用列向量生成算法,降低了航班恢复的成本。这些研究主要集中在提前规划更为合理的航班时刻表方面,而在航班延误当天进行实时恢复的同时不影响盈利能力的研究较为有限。因此,有学者基于启发式算法提出了航班延误实时恢复的算法模型。2008年,丁建立等^[4]将局部搜索方法引入到粒子群算法中,提出了求解航班延误恢复调度问题的混合粒子群算法。2017年,XU Bo等^[5]提出了一种基于尾流涡旋建模方法的蚁群算法,用来解决机场跑道

调度系统中的飞机调度问题,用以最小化最大调度时间。上述研究大都采用了启发式算法,但这类算法具有易陷入局部最优、收敛速度慢等不足。此外启发式算法只能得到问题一个解而非解决策略,因此这类算法在面对相似问题时往往仍需要重新迭代计算最优解且不具有迁移学习能力。2019年,S. IKLI等^[6]基于马尔可夫决策过程,将排班问题建模为一个由状态、行动、转换和成本组成的环境,并且在R.MUNOS等^[7]工作的基础上提出了一种新型的启发式搜索方法,该方法从所有飞机都可以降落的初始状态开始,在有限的时间内给出飞机降落的最佳顺序。2015年,I.B.SOARES等^[8]考虑在单一跑道上安排飞机起飞的问题,将这一过程建模为马尔科夫决策过程(MDP),通过Q-learning强化学习算法合理分配飞行器起飞时间窗口。2021年,李亚飞等^[9]基于深度Q神经网络模型解决了舰面甲板环境下舰载机的保障作业实时调度问题,并给出了系统的状态空间等一系列特征的定义方法。目前,强化学习算法在排班作业调度等组合优化问题中已有广泛的应用,但在航班延误恢复重排班方面的研究较少。

文中研究成果的主要贡献和创新点在于将航班延误恢复重排班这一优化问题表述为马尔科夫决策过程(MDP),设计航班延误的损失计算函数,并通过深度强化学习算法得出最优排班解,提出了一种基于强化学习算法的机场航班延误恢复重排班算法。借助卷积神经网络提取数据特征的能力以及奖励函数的设计,该算法能够避免启发式算法易陷入局部最优的缺陷,同时采用随机梯度算法进行梯度下降训练神经网络,加快收敛速度,使得航班延误恢复的强化学习算法较启发式算法在时间效率和优化效果上均取得较好的表现。

1 机场航班延误恢复重排班模型

1.1 航班延误恢复问题定义与建模

当机场发生多个航班延误时,导致多数飞行器和航班滞留机场不能按时起飞,此时延误时间越久,对航空公司、机场和旅客造成的总损失越大。因此航班延误的总损失与航班延误时长成正相关关系。参考现有的研究文献,航班延误总损失由隐性损失和显性损失构成^[4]。

隐性损失主要由航班乘客由于航班延误而不再

选择民航出行的概率决定,乘客失望率函数^[10]如式(1):

$$d = \sqrt[3]{(m_f/60)^2/29}, 0 \leq d \leq 1 \quad (1)$$

式中: d 为旅客失望率; m_f 为航班 f 的延误时长, min。

旅客失望溢出成本如式(2):

$$C = v_f \times w_f \times \mu \quad (2)$$

式中: v_f 为该航班 f 上的乘客数; w_f 为该航班 f 的平均票价。

显性损失主要从航空公司、机场和旅客3个方面考虑。从航空公司角度考虑,主要损失为由于航班延误而无法进行营利,这与航班的载客率和净利润率相关。航班的平均票价为 w_f ,则航班 f 单位时间的盈利损失如式(3):

$$C_A = N_f p_f \eta_f w_f m_f / t \quad (3)$$

式中: p_f 为平均净利润率; η_f 为航班客座率; N_f 为航班最大载客人数; t 为平均飞行时间。

从机场角度考虑,主要损失为飞行器和航班旅客滞留所造成的损失,这与延误时长成正相关。机场的损失如式(4):

$$C_a = o_f m_f \quad (4)$$

式中: o_f 为机场平均延误损失。

航班旅客延误受到的影响差异较大。假设航班 f 的旅客平均延误损失为 c_f ,则航班旅客的延误损失如式(5):

$$C_p = c_f m_f \quad (5)$$

同时,为统一衡量航空公司、机场和旅客三者的损失,应对不同情况下三方面的权重不同的情况,引入偏重系数,令 μ_1 、 μ_2 、 μ_3 分别代表三者的权重。此外,还需要考虑航班的重要性因子 γ ,航班重要程度越高,重要性因子越大。

将航班的初始排班状态表示为 S_0 ,每个决策动作会调整其中2个航班的顺序,经过 k 次的调整之后航班排班状态为 S_k 。调整航班排班顺序的动作集合 $A = \{a_{1,2}, a_{2,3}, a_{3,4}, \dots, a_{m,n}\}$,其中决策动作 $a_{m,n}$ 表示交换航班 f_m 和 f_n 的起飞顺序,航班被表示为 $f = \{m_f, w_f, \eta_f, p_f, N_f, o_f, c_f\}$ 。通过计算可得出当前排班状态 S 的总损失:

$$C_S = \sum_f^F (1 + \gamma) (C + \mu_1 C_A + \mu_2 C_a + \mu_3 C_p) \quad (6)$$

式中: $f \in F$,指受到延误影响的航班; γ 为重要性因子。

航班延误恢复的目的是最小化该目标函数。

此外,为建立航班延误恢复约束条件,定义以下符号:

1) 如果航班 $f \in F$ 属于航线 $l \in L$ 时,令 $b_{f,l} = 1$;否则 $b_{f,l} = 0$ 。

2) 如果飞机 $e \in E$ 执行了航线 l ,则令 $z_{e,l} = 1$;否则 $z_{e,l} = 0$ 。

3) 如果航班 f 取消, $y_f = 1$;否则 $y_f = 0$ 。

则航班延误恢复约束条件如式(7)~式(10):

$$\sum_{l \in L} \sum_{e \in E} b_{f,l} z_{e,l} + y_f = 1, \forall f \in F \quad (7)$$

$$\sum_{l \in L} z_{e,l} \leq 1, \forall e \in E \quad (8)$$

$$m_f \geq 0, \forall f \in F \quad (9)$$

$$N_f \geq v_f, \forall f \in F \quad (10)$$

其中式(7)为航班覆盖约束,表示每个航班只能执行一次,或者取消该航班;式(8)为飞机任务约束,表示每个飞机最多只能执行一条航线;式(9)表示任意航班的起飞时间不能早于计划起飞时间;式(10)表示该航班的乘客数必须小于或等于该航班飞行器最大乘客数,其中, N_f 为最大载客数, v_f 为乘客数。

1.2 航班延误恢复重排班模型

将机场航班延误恢复重排班算法与机场A-CDM实时监控系統结合起来,对机场延误航班进行实时监控和恢复,如图1。机场信息管理系统会对机场的延误情况进行实时监控,当延误发生时,其是否需要延误恢复进行判断。需要进行延误恢复重排班时,启动重排班系统,将乘客、飞行器和航班等数据信息构建为初始航班排班状态,由强化学习模块不断优化排班状态或者由管理人员直接制定得到最终排班方案。

在强化学习模块中,策略函数根据状态特征给出动作,将动作作用到状态中改变排班状态,同时计算得到动作的奖励值,用来判断动作的好坏程度。重复上述过程,使得排班状态不断改变,最终获得总损失 L_F 最小的最优排班状态。在这个过程中,强化学习模块会通过不断训练策略函数,使之不断优化,逐渐拟合,最终能够根据状态特征给出最优动作,提高重排班的效率。




图1 机场航班延误恢复重排班模型

Fig. 1 Airport flight delay recovery rescheduling model

2 航班延误恢复强化学习算法

笔者提出了一种航班延误恢复深度学习算法,通过航班延误恢复重排班算法模型中状态转移方程和奖励函数的设计,给出决策动作的策略函数模型构建和训练算法。

2.1 航班延误恢复的马尔科夫决策过程

强化学习模型的基础是构建马尔科夫决策过程。将不断调整航班排班的过程和航班延误总损失 L_F 及调整航班排班顺序的动作集合 A 结合起来,可将航班延误恢复这一最优化问题视为马尔科夫决策过程(MDP)。对于给定的航班排班状态 S_k ,根据制定的策略给出动作集合 A 的概率分布 x_k ,并根据 x_k 选择出最佳动作 a_k^{best} 。第 k 次决策时的排班状态被表示为多维特征向量 $S_k = [f_{k,1}, f_{k,2}, f_{k,3}, \dots, f_{k,n}]$,其中 $f_{k,n}$ 表示第 k 次决策状态中的第 n 架航班。此马尔科夫决策过程遵循从 k 到 $k+1$ 的动态转换方程 $S_{k+1} \sim P(S_k, a_k^{\text{best}})$,即将动作 a_k^{best} 作用到状态 S_0 中。同时根据奖励函数计算第 k 次决策的奖励值 r_k 。过程是否终止由 ψ 决定,当已处于最优的排班状态或迭代次数已经达到上限时, $\psi=1$,否则 $\psi=0$ 。

重复上述转换过程,可以得到一个序列:

$$\zeta = \{(S_0, a_0, r_0, \psi_0), (S_1, a_1, r_1, \psi_1), \dots, (S_k, a_k, r_k, \psi_k), \dots, (S_T, a_T, r_T, \psi_T)\} \quad (11)$$

式中: a_k 为第 k 次决策选出的动作; T 为迭代次数上限。

设 $R = r_0 + r_1 + \dots + r_T$, 当 R 取到最大值时所用的

策略为最佳策略。

2.2 排班状态转移方程和奖励函数

状态转移方程是对航班排班状态特征向量的转移描述。状态转移方程 $S_{k+1} \sim P(S_k, a_k^{\text{best}})$ 表示在决策阶段 $k = 0, 1, \dots, K$ 时,对于给定的 a_k^{best} 和 S_k ,根据 a_k^{best} 将 S_k 中的对应航班交换起飞顺序,并且对相应航班 f 的值进行相应修改。

奖励函数用来判断动作对当前状态的影响好坏,主要考虑航班的延误损失值。奖励函数的目的是使得策略函数选择尽可能降低未来延误总损失的动作。根据第 1.1 节构建的延误损失函数[式(6)],设置奖励函数为决策动作对排班状态所造成的影响程度,即:

$$r_k = L_{S_k}^{F^*} - L_{S_{k+1}}^{F^*} \quad (12)$$

式中: F^* 为受决策动作 a_k 影响的航班集合; $L_{S_k}^{F^*}$ 为第 k 次决策前时排班状态 S_k 的总损失。

式(12)采用迭代前后 2 个状态的损失之差作为奖励函数,能够直观地反映出决策动作的好坏。

2.3 基于神经网络策略函数的构建

构建参数为 θ 的神经网络作为策略函数 π_θ 的核心部分,如图 2。策略函数 $\pi_\theta(\cdot)$ 的输入为排班状态特征向量 S ,输出为 $x = \pi_\theta(a|S) \in [0, 1]$,其中, x 为给定特征向量 S 时动作空间 A 的概率分布。策略函数 $\pi_\theta(\cdot)$ 中神经网络 θ 的参数权重初值时被置为随机值,在训练过程中通过特征状态和决策空间探索最佳的操作决策,其随机性随着训练过程的进行而降低。神经网络 θ 的结构如图 3,其输入为状态特

征矩阵,隐藏层第 1 层为一维卷积神经网络,该层网络用来提取相邻航班的数据特征,通过一层拉平层(Flatten 层)展开,再由 2 层全连接层组成,每层的输出经过一层 ReLU 激活函数^[11],最后为输出层。在策略函数中,对于给定的 S_k, θ 将生成中间决策向量 $\bar{X}_k = (\bar{x}_k^1, \bar{x}_k^2, \bar{x}_k^3, \dots, \bar{x}_k^n)$, 其中 $\bar{x}_k^i$ 用来表示动作集合 A 中对应动作的选择偏好程度。

从动作集合 A 中采样的某些决策动作可能会违反相关约束条件[式(7)~式(10)]。为了解决这一问题,策略函数 $\pi_\theta(\cdot)$ 中加入筛选机制。通过一层筛选机制 f_k 生成中间动作向量 $f(\bar{X}_k)$:

$$f(\bar{X}_k) = \begin{cases} \bar{X}_k, & \text{满足式(7)~式(10)} \\ -\infty, & \text{不满足式(7)~式(10)} \end{cases} \quad (13)$$

掩码 f_k 将不满足约束条件的决策动作的偏好程度设置为 $-\infty$ 。然后, $f(\bar{X}_k)$ 通过 softmax 函数,使得最终决策动作的概率分布 X_k 为:

$$X_k = \pi_\theta(x_k = x_k^i | S_k) = \frac{\exp[f_k(\bar{x}_k^i)]}{\sum_{j=0}^n \exp[f_k(\bar{x}_k^j)]} \quad (14)$$

策略函数的最终输出 X_k 是大小为 $|A|$ 的向量,其取值范围是 $[0, 1]$, 对应于每个决策动作被选择的概率。




图 2 策略函数结构

Fig. 2 Structure of the policy function




图 3 神经网络 θ 结构

Fig. 3 Structure of the neural network θ

2.4 基于奖励函数和优势函数的训练算法

通过学习训练过程,当策略函数 $\pi_\theta(\cdot)$ 接近笔者建立的 MDP 最优策略时,航班排班顺序就可以根

据 $\pi_\theta(\cdot)$ 进行优化。参考文献[12]、文献[13]中的深度 Q 神经网络(DQN)和近端策略优化算法(PPO),构建了一个优化算法框架,能够找到最佳的参数 θ_{best} 使以下目标函数最大化:

$$R(\theta) = E_{\pi_\theta, S_0} \left(\sum_{k=0}^T r_k \right) \quad (15)$$

式(15)表达的含义是在给定随机策略 $\pi_\theta(\cdot)$ 和初始状态 S_0 情况下转换序列 ζ 的奖励值之和的期望值,该值的实际意义是初始排班方案的延误成本损失和最终排班状态损失之差,其中转换序列 ζ 如式(11),其终止于 $\psi_k = 1$ 或 $k = T$ 的阶段。

图 4 总结了从参数为 θ 的特定策略函数中对样本转换序列 ζ 总奖励 R 的计算。




图 4 算法 1 计算基于策略函数奖励值流程

Fig. 4 Process of calculating reward values based on policy functions with algorithm 1

为了保证收敛和求解的效率,式(15)的最大化问题采用算法2(图5)求解。




图5 算法2更新策略函数流程

Fig. 5 Updating policy function with Algorithm 2

该算法共包含 M 次迭代,每次迭代进行 e 次训练。在每次迭代过程中,将参数为 θ_i 的由算法1获取的转换序列加入序列集合 $\{\zeta_i\}$ 中,得到长度大于 B 的由 (S_k, a_k, r_k, ψ_k) 组成的序列。在循环 $j=1, 2, \dots, J$ 中,首先从序列 $\{\zeta_i\}$ 中随机采样大小为 B 的小批量序列 Z_j ,并打乱其先后顺序,然后根据 Z_j 对神经网络的参数进行梯度下降更新。将前迭代中的参数 θ_i 更新为:

$$\theta_{i+1} = \arg \max_{\theta} L^{KPLEN}(\theta) \quad (16)$$

式(16)通过 Adam 优化方法^[14]的随机梯度搜索迭代求解,其中损失函数 $L^{KPLEN}(\theta)$ 定义为:

$$L^{KPLEN}(\theta) = \frac{1}{B} \sum_{k \in Z_j} [L^{CLIP}(\theta) + \omega L^{KL}(\theta)] \quad (17)$$

式中: ω 为权重参数。

损失函数 $L^{KPLEN}(\theta)$ 由 $L^{CLIP}(\theta)$ 和 $L^{KL}(\theta)$ 两部分组成。

$$L^{CLIP}(\theta) = \min \{ \beta_k(\theta) V_k, \alpha[\beta_k(\theta), 1-\varepsilon, 1+\varepsilon] V_k \} \quad (18)$$

式中: $\varepsilon \in (0, 1)$ 为预设参数; α 为截断函数,其作用是将 $\beta_k(\theta)$ 能够取到的值限制在区间 $[1-\varepsilon, 1+\varepsilon]$ 内。其中:

$$\beta_k(\theta) = \frac{\pi_{\theta}(x_k | S_k)}{\pi_{\theta_i}(x_k | S_k)} \quad (19)$$

$$V_k = r_k + \lambda \pi_{\theta}(S_k) \quad (20)$$

加入 $\beta_k(\theta)$ 的目的是将算法中 θ_{i+1} 的搜索限制在接近当前参数集 θ_i 的预定义范围内。

根据式(19),如果策略函数 π_{θ} 性能较差 ($V_k < 0$),则其更新时不加任何约束,否则 ($V_k > 0$),其调整应被参数 ε 限制。因此,寻找一个最大 $L^{KPLEN}(\theta)$ 的 θ 将导致在未来迭代中产生更高奖励的决策选择。

式(20)为一个优势函数,它反映了从策略函数 $\pi_{\theta}(\cdot)$ 中所选决策 a_k 相对于其他决策动作的优势。具体来说,如果决策 a_k 能带来更小的预期总延误,那么 V_k 取得较大正值;如果 x_k 使得预期总延误增大, V_k 取得负值。式(20)利用折扣因子 $\lambda \in [0, 1]$ 平衡由于过度简化未来奖励而导致的估计偏差和方差^[13]。

此外,为了保证对决策空间的充分探索,对函数 $L^{KPLEN}(\theta)$ 增加了熵损失函数:

$$L^{KL}(\theta) = - \sum_{j=1}^n \pi_{\theta}(\bar{x} | S_k) \log[\pi_{\theta}(\bar{x} | S_k)] \quad (21)$$

最大化比熵损失函数项增加了与策略函数 $\pi_{\theta}(\cdot)$ 的决策抽样相关随机性,从而引入了“探索”行为,以尝试特定状态下的不同决策^[15]。权重 ω 是为了平衡决策空间的探索和利用,此参数会随着训练的进行不断减小,从而在迭代中减少探索行为和增加对策略函数的利用行为,以确保收敛。

3 仿真实验结果及分析

3.1 实验准备

选取国际某机场2016年4月22日374个航班数据进行试验。该机场当天因受到暴风雪的影响,管理部门决定在2016年4月22日18:00—21:00

之间关闭机场,在该时间段内该机场不能起飞或降落任何航班,造成了大量的飞行器和旅客滞留在机场内。由于该机场的跑道限制,机场每 5 min 最多能起飞 5 架飞机,同时降落 5 架飞机。例如在 21:00—21:05 之间(不包括 21:05 时间点)最多有 5 个起飞航班和 5 个降落航班,其起飞和降落时间均可以按 21:00 计算,以此类推。受到此次天气直接或间接影响导致延误滞留的航班达 111 个,受影响的旅客达 10 373 人。规定当天的航班必须要在当日 24:00 前完成延误恢复的工作。

整理航班数据信息模拟实时数据流输入,取航班的延误时长、平均票价、乘客人数、座位数、所分配飞行器的平均延误损失 o_f 及旅客平均延误损失 C_p 作为航班向量,设定旅客平均延误损失 $C_p = 50$ 元,飞行器的平均延误损失 o_f 如表 1^[4]。此外,中国民用航空业作为中国公共基础行业要为人民大众服务,以人民为主,因此一般情况下取偏重系数 $\mu_1 = \mu_2 = 1.0, \mu_3 = 1.1, \gamma = 0$,另外实际应用时可将该参数暴露给机场管理人员,管理者可根据机场实际延误情况进行修改。

表 1 不同机型延误损失

Table 1 Delay loss for different aircraft models

机型	最大起飞质量/t	尾流类型	延误运营损失/元
重型机	>136	重型尾流	4 167
中型机	7~136	中型尾流	2 916
轻型机	<7	轻型尾流	208

3.2 实验结果

强化学习智能体策略函数中的神经网络由 4 层神经网络表示,包括一层卷积神经网络,一层拉平层和 2 层全连接层。通过设置不同的神经元数量(100、200、300、400 个)并测试不同的激活函数(ReLU 和 Tanh)来进行超参数调优。最终试验采用一层步长为 1,卷积核数量为 8,窗口长度为 2 的卷积神经网络,一层拉平层和 2 层神经元个数分别为 300、200 的全连接层。其余超参数参考文献[13]设定并进行多次对比试验,设定折扣因子 $\lambda = 0.9$,参数 $\varepsilon = 0.2$,权重 $\omega = 0.99$, ω 随着训练过程逐渐减少直至 0.01,设置总迭代次数 $M = 10\ 000$,每次迭代的训练次数为 16 次,样本量 $B = 128$ 个,Adam 随机梯度算法的学习率设置为 0.01。采用 Python 编码脚本,试验运行在 linux 系统中,内存 128 G,CPU 为 Intel(R) Xeon(R) Gold 5215 CPU @ 2.50 GHz。

算法得出的优化结果与实际航班恢复数据相比,延误时间降低了 7.23%,延误损失降低了 7.83%,其对比结果如表 2。

表 2 延误损失对比

Table 2 Comparison of delay loss

优化项	延误总时长/min	延误损失/元
原时刻表成本	538 860	1 137 064.14
强化学习算法优化成本	499 922	1 047 977.68
降低比率/%	7.23	7.83

航班的延误总损失变化曲线和延误总时长变化曲线如图 6、图 7。训练迭代初期策略函数以更大概率随机选择决策动作用以训练,因此延误损失和延误总时长保持相对不变。随着迭代次数的增加,策略函数逐渐拟合,延误总损失和延误总时长则会逐渐下降。如果直接使用预训练的神经网络作为策略函数(图 8、图 9),延误总损失和延误总时长将在 1 400 次迭代内逐渐达到最低。由此可见,求解速度上使用预训练参数的策略函数比使用非预训练参数的策略函数提高了数倍。

将航班延误恢复强化学习算法模型与启发式粒子群算法(PSO)^[16]以及遗传算法(GA)^[17]在同性能的计算机和相同数据上进行对比分析,进行基准对比试验。2 种对比算法的迭代次数都设置为 5 000,其中每一代要评估的候选解决方案的数量都为 50。其中粒子群算法的学习率设置为 2.0^[4];遗传算法的交叉率设置为 0.95,突变率设置为 0.15。算法给出的候选解将通过 2.2 节中采用的掩码方案进行筛选。此外,通过式(6)对每个候选解进行评估,计算相应的目标函数值。由于强化学习算法和启发式算法每次迭代所需要的时长不同,试验使用已训练时长作为对比基准。




图 6 训练过程中延误总损失变化曲线

Fig. 6 Variation curve of delay loss during training process




图 7 训练过程延误总时长变化曲线

Fig. 7 Variation curve of total duration of delay during training process




图 8 预测过程中延误总损失变化曲线

Fig. 8 Variation curve of total delay loss in prediction process




图 9 预测过程中延误总时长变化曲线

Fig. 9 Variation curve of total duration of delay in the prediction process

深度强化学习算法、粒子群算法以及遗传算法迭代过程中航班排班延误总损失随计算时间的变化关系如图 10。这 3 种算法均以 Python 语言实现,运行在内存为 128 G、CPU 为 Intel(R) Xeon(R) Gold 5215 CPU @ 2.50 GHz 的 linux 系统主机上。由图 10 可以看出,在相同主机配置的环境下,通过策略函数和优势函数对状态和策略进行参数化,所采用

的深度强化学习算法在时间效率和优化效果上均取得了更好的效果。这种差异可能是由于强化学习算法使用了基于卷积神经网络构建的策略函数,可以有效提取航班之间的局部特征关系,表现出更好的优化效果。同时神经网络可以采用有效的 Adam 随机梯度算法进行梯度下降,加快神经网络训练拟合的效率。而 PSO 算法和 GA 算法受限于初始解空间和算法本身的限制,易受困于局部最优且较难收敛,因而在最终结果的表现上,时间效率和优化效果相较于强化学习算法更为不理想。




图 10 不同算法效果对比

Fig. 10 Comparison of the effect of different algorithms

为进一步验证基于强化学习的机场航班延误恢复重排班算法的实时性,对试验时间和结果进行统计,为保证系统的实时性,在对航班进行重排班时使用预训练好的神经网络作为策略函数。系统在各个时间给出的航班排班方案和延误总损失如表 3。

由表 3 可知,当机场发出重排班指令后,系统模型能够在 60 s 内对所有延误航班进行重排,并降低航班延误总损失,表明算法具有较强的时效性。

表 3 延误总损失时间统计

时间/s	延误总损失/元	降低百分比/%
0	1 136 814.791	0
20	1 081 870.154	4.83
40	1 056 164.043	7.09
60	1 047 977.68	7.83

4 结 论

笔者提出了一种航班延误恢复强化学习算法,算法基于深度神经网络参数化策略函数,对最小化延误损失排班策略进行学习训练,能够有效降低排班的延误损失。笔者对国际某机场的 111 班次延误航班进行试验,分析算法在航班延误恢复问题中的表现,结论如下:

1) 算法能够将航班延误总损失降低 7.83%,延

误总时长降低 7.23%, 表明算法具有较好的性能和效率, 能够有效降低航班延误对航司、机场和民航旅客造成的损失。

2) 对比粒子群算法及遗传算法, 航班延误恢复强化学习算法在时间效率和性能上均取得较好效果, 系统具有较好的实时性, 在机场航班延误恢复重排班、降低延误损失等问题上具有较好的表现。

目前航班延误恢复重排班强化学习算法的性能会随着维度的增加而降低, 在面对更高维度的问题时表现不佳, 因此当延误航班的规模进一步扩大时算法性能会下降。为进一步提高模型的可靠性和排班的算法效率, 下一步工作将考虑改善神经网络结构和训练算法, 提高神经网络预测的准确性, 使得模型的性能进一步提升。

参考文献(References):

- [1] ŞAFAK Ö, GÜREL S, AKTÜRK M S. Integrated aircraft-path assignment and robust schedule design with cruise speed control [J]. *Computers & Operations Research*, 2017, 84: 127-145.
- [2] WU Chenglung, LAW K. Modelling the delay propagation effects of multiple resource connections in an airline network using a Bayesian network model [J]. *Transportation Research Part E: Logistics and Transportation Review*, 2019, 122: 62-77.
- [3] 何坚, 果红艳, 姚远, 等. 基于有效中转时间预测的不正常航班恢复技术[J]. 北京航空航天大学学报, 2022, 48(3): 384-393.
HE Jian, GUO Hongyan, YAO Yuan, et al. Irregular flight recovery technique based on accurate transit time prediction [J]. *Journal of Beijing University of Aeronautics and Astronautics*, 2022, 48(3): 384-393.
- [4] 丁建立, 王新茹, 徐涛. 航班延误恢复调度的混合粒子群算法[J]. 交通运输工程学报, 2008, 8(2): 90-95.
DING Jianli, WANG Xinru, XU Tao. Hybrid particle swarm optimization arithmetic for recovery scheduling of flight delays [J]. *Journal of Traffic and Transportation Engineering*, 2008, 8(2): 90-95.
- [5] XU Bo. An efficient Ant Colony algorithm based on wake-vortex modeling method for aircraft scheduling problem [J]. *Journal of Computational and Applied Mathematics*, 2017, 317: 157-170.
- [6] IKLI S, MANCEL C, MONGEAU M, et al. An optimistic planning approach for the aircraft landing problem [C]// *Air Traffic Management and Systems IV: Selected Papers of the 6th ENRI International Workshop on ATM/CNS (EIWAC2019)*. Singapore: Springer, 2021: 173-188.
- [7] MUNOS R. From bandits to Monte-Carlo tree search: The optimistic principle applied to optimization and planning [J]. *Foundations and Trends © in Machine Learning*, 2014, 7(1): 1-129.
- [8] SOARES I B, DE HAUWERE Y M, JANUARIUS K, et al. Departure management with a reinforcement learning approach: Respecting CFMU slots [C]// *2015 IEEE 18th International Conference on Intelligent Transportation Systems*. IEEE, 2015: 1169-1176.
- [9] 李亚飞, 吴庆顺, 徐明亮, 等. 基于强化学习的舰载机保障作业实时调度方法[J]. 中国科学: 信息科学, 2021, 51(2): 247-262.
LI Yafei, WU Qingshun, XU Mingliang, et al. Real-time scheduling for carrier-borne aircraft support operations: A reinforcement learning approach [J]. *Scientia Sinica (Informationis)*, 2021, 51(2): 247-262.
- [10] 赵秀丽, 朱金福, 郭梅. 不正常航班延误调度模型及算法[J]. 系统工程理论与实践, 2008, 28(4): 129-134.
ZHAO Xiuli, ZHU Jinfu, GUO Mei. Study on modelling and algorithm of irregular flight delay operation [J]. *Systems Engineering-Theory & Practice*, 2008, 28(4): 129-134.
- [11] GLOROT X, BORDES A, BENGIO Y. Deep sparse rectifier neural networks [C]// *The 14th International Conference on Artificial Intelligence and Statistics (AISTATS)*, Fort Lauderdale, Florida, USA, 2011: 315-323.
- [12] MNH V, KAVUKCUOGLU K, SILVER D, et al. Playing Atari with deep reinforcement learning [C]// *Proceedings of the NIPS Workshop on Deep Learning*. Lake Tahoe: MIT Press, 2013.
- [13] 梁星星, 冯旸赫, 马扬, 等. 多 Agent 深度强化学习综述[J]. 自动化学报, 2020, 46(12): 2537-2557
LIANG Xingxing, FENG Yanghe, MA Yang, et al. Deep multi-agent reinforcement learning: A survey [J]. *Acta Automatica Sinica*, 2020, 46(12): 2537-2557.
- [14] KINGA D, ADAM J B. A method for stochastic optimization [C]// *The 3rd International Conference on Learning Representations (ICLR)*, San Diego, CA, USA, 2015.
- [15] MNH V, BADIA A P, MIRZA M, et al. Asynchronous methods for deep reinforcement learning [C]// *The 33rd International Conference on Machine Learning*. New York, USA, 2016: 1928-1937.
- [16] MARINI F, WALCZAK B. Particle swarm optimization (PSO): A tutorial [J]. *Chemometrics and Intelligent Laboratory Systems*, 2015, 149: 153-165.
- [17] NIU Huimin, ZHOU Xuesong. Optimizing urban rail timetable under time-dependent demand and oversaturated conditions [J]. *Transportation Research Part C: Emerging Technologies*, 2013, 36: 212-230.

(责任编辑: 罗素琴)